NEXVIA AEGIS V9-M4 Independent Statistical Audit

Executive Summary & Pre-Execution Readiness Assessment

Autonomous Verification Subsystem (Google DeepMind Antigravity)

Git Branch: v9.0-runtime-assurance · Commit: 083ade9 · Date: October 25, 2026

CRITICAL GOVERNANCE NOTICE:
This document reports an independent statistical, mathematical, and implementation audit of the NEXVIA AEGIS V9-M4 confirmatory holdout evaluation harness. **No real holdout execution was authorized or performed as part of this audit.** All empirical tests reported herein are based strictly on synthetic mock records or unit regression baselines. The reserved holdout seed blocks (73000..74439 for mixture holdout and 75000..75119 for scenario holdout) remain completely uninstantiated and 100% untouched. This audit report does NOT constitute authorization to execute V9-M4.

1 English Executive Summary (For Research Evaluation)

1.1 Context and Scope of the Audit

Milestone V9-M4 constitutes the terminal confirmatory evaluation of the certified runtime assurance policy $\hat{\pi}$ = V9_CAND_1_TIER1_STRICTEST on reserved holdout data. Because holdout partitions are strictly single-shot and unrepeatable, this independent statistical audit was executed prior to any holdout simulation to verify:

1. Complete mathematical and algorithmic fidelity to the preregistered experiment protocol (`docs/v9_experiment_protoc` and `docs/v9_m4_readiness_review.md`).
2. Exactness and boundary stability of statistical estimators for Hypotheses H_1 through H_5.
3. Robustness of fail-closed execution guards and physical holdout partition isolation.
4. Absence of algorithmic regressions across the codebase.

1.2 Summary of Verified Successes

- **Regression Invariance:** All 125 repository regression tests passed with zero failures in 30.72 seconds.
- **Selective Risk Inversion (H_1):** Mathematical derivation confirmed that $M \geq 59$ accepted decisions is the exact theoretical threshold below which 95% Clopper–Pearson certification of $R_{\text{sel}} \leq 0.05$ is impossible even under zero false successes ($U_{\text{CP},1}(0, 58) \approx 0.0503 > 0.05$ vs. $U_{\text{CP},1}(0, 59) \approx 0.0495 \leq 0.05$). The harness strictly prevents certification gaming when false successes are observed ($M = 59, K = 1 \implies U_{\text{CP},1} \approx 0.0779 > 0.05$, correctly rejected).
- **Coverage Utility Precondition (H_4):** Correctly evaluates empirical sample coverage $\hat{C} \geq 0.35$ as an operational utility floor, cleanly distinguishing an empirical precondition from an inferential lower confidence bound. At $M = 503$, it fails; at $M = 504$, it passes. Anti-gaming logic overrides H_1 if coverage is below 35%.
- **Paired Comparisons (H_2, H_3):** Exact McNemar testing, Newcombe paired difference intervals (Method 10), and Student's t lower confidence bounds for TSR noninferiority ($\text{LCB}_{95} > -0.05$) are mathematically exact.
- **Holdout Partition Isolation:** Direct filesystem audits confirm that zero production holdout manifests or output directories exist. The fail-closed execution guard blocks live execution unless an explicit authorization token is supplied, and enforces a preflight double-lock.

1.3 Identified Findings Requiring Remediation

1. **Finding M4-F02 (High Severity — Estimand Inversion in Berger IUT for H_5):** The preregistered protocol specifies that the multi-scenario safety envelope (H_5) is evaluated using Berger's Intersection-Union Test over *unconditional false-success incidence* $R_{\text{inc},s} = K_s/N_s$ ($N_s = 120$). In `experiments/v9_evaluate_holdout.py`, line 698 computes binomial p-values over *accepted decisions* (M_s) with a fallback of $p = 1.0$ under total abstention ($M_s = 0$). In catastrophic fault scenarios (e.g.

`FAULTY_REFERENCE_SENSOR`), safe runtime assurance abstains on 100% of episodes ($M_s = 0, K_s = 0$), achieving unconditional incidence of $0/120 = 0.0\%$ ($p = 0.0021 \leq 0.05$). However, because the harness assigns $p = 1.0$, the Berger IUT is guaranteed to fail.
Remediation: Compute $p_{\text{inc},s} = \text{binom.cdf}(fs_s, n_s, 0.05)$ on $N_s = 120$ for the IUT, while continuing to report selective risk descriptively.

2. **Finding M4-F03 (Medium Severity — Implicit Key Ordering in Paired Comparisons):** Paired loops use `zip(records, baseline_records)` without explicitly verifying matching seeds and scenarios.
Remediation: Add explicit assertions `assert r["seed"] == v["seed"] and r["scenario"] == v["scenario"]`.

1.4 Pre-Execution Audit Recommendation

We issue an overall audit finding of:

$$\textbf{M4_STATISTICAL_AUDIT_PASS_WITH_QUALIFICATIONS} \tag{1}$$

Execution of V9-M4 must remain strictly blocked until Finding M4-F02 and Finding M4-F03 are remediated and verified.

2 (Thai Executive Summary)

2.1 วัตถุประสงค์ของการตรวจสอบ

การตรวจสอบครั้งนี้เป็นการตรวจสอบความถูกต้องทางสถิติและสถาปัตยกรรมซอฟต์แวร์แบบอิสระ (Independent Statistical Audit) สำหรับชุดประเมินผลชุดข้อมูลทดสอบขั้นสุดท้าย (Confirmatory Holdout Evaluation Harness: V9-M4) ก่อนที่จะมีการพิจารณาอนุมัติให้ดำเ
(Reserved Holdouts)

2.2 ผลการตรวจสอบที่ผ่านเกณฑ์อย่างสมบูรณ์

1. **การผ่านการทดสอบแบบถดถอย 100% (Regression Pass):** ชุดทดสอบระบบทั้งหมด 125 รายการในคลังโค้ดผ่านการทดสอบทั้งหมด (125 passed in 30.72s) โดยไม่มีข้อผิดพลาดใด ๆ

2. **ความถูกต้องของการควบคุมความเสี่ยงแบบเลือก (Selective Risk H_1):**

   - ได้รับการพิสูจน์ทางคณิตศาสตร์แล้วว่า เกณฑ์ขั้นต่ำที่ต้องยอมรับการตัดสินใจอย่างน้อย $M \geq 59$ ครั้ง เป็นขอบเขตทางทฤษฎีที่จำเป็น (Exact Mathematical Bound) สำหรับการรับรองความเสี่ยงต่ำกว่า 5.0% ที่ระดับความเชื่อมั่น 95%
   - ระบบป้องกันการทุจริตผลการทดสอบ (Anti-Gaming Protection) ทำงานได้อย่างสมบูรณ์ หากเกิด False Success ขึ้นแม้เพียง 1 ครั้งใน 59 ครั้ง ($K = 1$) ระบบจะปฏิเสธการรับรองทันที ($U_{\text{CP},1} \approx 7.79\% > 5.0\%$)

3. **การปกป้องการทำงานและการแยกส่วนข้อมูล (Holdout Isolation & Execution Guard):**

   - ตรวจสอบยืนยันแล้วว่า **ไม่มีการสร้างหรือเข้าถึงชุดข้อมูล Holdout จริงใด ๆ ทั้งสิ้น** ไฟล์ Manifest และโฟลเดอร์ผลลัพธ์ของ Holdout ยังไม่ถูกสร้างขึ้น (100% Clean)
   - ระบบป้องกัน Single-Shot Overwrite และ Fail-Closed Guard ทำงานได้อย่างรัดกุม โดยจะปฏิเสธการรันจริงทันทีหากไม่มี Token อนุมัติ

2.3 ประเด็นสำคัญที่ต้องแก้ไขก่อนการรันจริง (Key Remediation Items)

- **ข้อตรวจพบ M4-F02 (ความสำคัญระดับสูง - High Severity):** ในการทดสอบสมมติฐานความปลอดภัยกรณีเลวร้ายที่สุด 12 สถานการณ์ (H_5 ผ่าน Berger Intersection-Union Test) โปรโตคอลกำหนดให้ทดสอบบน **อัตราการเกิดอุบัติการณ์จริงแบบไม่มีเงื่อนไข (Unconditional Incidence: $N_s = 120$)** แต่ในโค้ดปัจจุบันได้นำจำนวนครั้งที่ยอมรับ (M_s) ไปคำนวณและตั้งค่า $p = 1.0$ เมื่อมีการละเว้นการทำงาน ($M_s = 0$) ส่งผลให้ในสถานการณ์ที่ระบบตรวจพบเซ็นเซอร์เสียหายรุนแรงและสั่งหยุดทำงานอย่างปลอดภัย ($FS = 0$) กลับถูกคิดค่า $p = 1.0$ จนทำให้การทดสอบ H_5 ล้มเหลว
แนวทางแก้ไข: ปรับแก้การคำนวณค่า p ของ IUT ให้ใช้ $N_s = 120$ ตามที่ระบุไว้ในโปรโตคอลหลักก่อนเริ่มการรันจริง

- **ข้อตรวจพบ M4-F03 (ความสำคัญระดับปานกลาง - Medium Severity):** เพิ่มการตรวจสอบความตรงกันของ Seed และ Scenario ในลูปการเปรียบเทียบคู่แบบชัดเจน (`assert r["seed"] == v["seed"]`) เพื่อป้องกันข้อผิดพลาดจากการเรียงลำดับข้อมูล

2.4 ข้อสรุปและสถานะของโครงการ

ผลการประเมินสถานะในภาพรวมคือ `M4_STATISTICAL_AUDIT_PASS_WITH_QUALIFICATIONS` (ผ่านการตรวจสอบโดยมีเงื่อนไขการปรับปรุ
โดยโครงการยังคง **ระงับการรันบนชุดข้อมูล Holdout จริงไว้โดยสมบูรณ์** จนกว่าจะดำเนินการแก้ไขข้อตรวจพบ M4-F02 และ M4-
F03 ให้เรียบร้อย